

Classificação de Sons Urbanos com Deep Learning

Otimização de Arquiteturas RNN, CNN e CRNN no UrbanSound8K

Aprendizagem Computacional 2

O Desafio: Modelação de Sons Não Estruturados

Este trabalho explora o desafio de classificar sons ambientais não estruturados, uma tarefa complexa devido à natureza caótica e ruidosa dos ambientes urbanos, que se distinguem marcadamente da fala ou da música.

CNN

Foco em texturas espectrais.

Deteta padrões visuais em espectrogramas, ideal para sons estacionários.

RNN

Foco na evolução temporal.

Captura sequências e mudanças ao longo do tempo, como o efeito Doppler.

CRNN

Híbrido: Espacial + Temporal.

Combina a capacidade da CNN para deteção de características com a análise temporal da RNN.

O Dataset: UrbanSound8K

Com 8.732 clips de áudio, distribuídos por 10 classes (ex: air_conditioner, car_horn), totalizando aproximadamente 8.75 horas de gravações. A alta dimensionalidade e variância dos dados justificam a necessidade de extração automática de características via Deep Learning, superando métodos clássicos de Machine Learning.

Protocolo Experimental e Integridade dos Dados

Um ponto crítico na nossa metodologia foi o protocolo de validação. O dataset UrbanSound8K é composto por 'fatias' de gravações longas. A literatura, especificamente Salamon et al., alerta que o uso de divisão aleatória causa '**Data Leakage**', onde o modelo memoriza o ruído de fundo em vez de aprender o som.

10-Fold Cross-Validation

Adotámos a Validação Cruzada de 10 Folds, seguindo a regra de ouro: **fragmentos da mesma gravação original permanecem isolados no mesmo fold**. Isto garante que o modelo seja testado em gravações completamente novas, refletindo a sua verdadeira capacidade de generalização e evitando otimismo irrealista nos resultados.



Pré-processamento: A Mudança de Paradigma

A engenharia de características é crucial para o desempenho do modelo. Duas abordagens foram exploradas para representar o áudio.


Iteração 1: MFCCs

Inicialmente, implementámos **MFCCs** (coeficientes espectrais), que são o padrão histórico em reconhecimento de fala. No entanto, a literatura, especificamente estudos como o de *Piczak (2015)* e *Hu et al. (2019)*, indica que os MFCCs aplicam uma **Transformação de Cosseno Discreta (DCT)**. Embora isto seja útil para modelos lineares (como GMMs) porque descorrelaciona os dados, para uma **Rede Neural Convolucional (CNN)** é prejudicial.

As CNNs funcionam através da deteção de padrões espaciais locais (como linhas verticais ou texturas horizontais). A DCT dos MFCCs 'destrói' essa textura visual, tornando o espectrograma 'pixelizado' e abstrato, como podem ver na imagem da esquerda.

Iteração 2: Log-Mel Spectrogram

Por isso, na nossa segunda iteração (v2), migrámos para **Log-Mel Spectrograms**. Ao removermos a etapa da DCT, preservámos a estrutura harmónica e os transiente do som. Isto permitiu que a nossa CNN 'visse' fisicamente o som — por exemplo, as linhas horizontais de uma sirene ou o padrão caótico de um martelo pneumático — resultando numa representação de entrada muito mais rica para a extração de características profundas.



❏ A adoção do Log-Mel Spectrogram foi uma decisão crítica, permitindo uma representação mais fiel e visualmente rica do áudio para as CNNs, superando as limitações dos MFCCs para esta tarefa.

Otimização da CNN: Menos é Mais


A evolução da arquitetura CNN demonstrou que a simplificação pode levar a ganhos significativos de performance, especialmente em datasets de menor dimensão, ao reduzir o overfitting e focar-se na aprendizagem de características robustas.

Input	MFCC	Log-Mel
Filtros (máx)	128	64
Pooling	(2,2)	(3,3)→(4,4)→(4,4)
Ativação	ReLU	ELU
Dropout	0.5	0.1 (conv) / 0.3 (dense)
Padding	'same'	'valid'
Acurácia	60.7%	68.7%
Ganho	-	+8.0%

- **Pooling Assimétrico:** Cria invariância temporal e de frequência, crucial para reconhecer padrões sonoros independentemente da sua posição exata no tempo ou frequência.
- **Redução de Filtros:** Evita o overfitting, especialmente com datasets limitados.
- **ELU:** Lida melhor com ruído e acelera a convergência em redes profundas.

CRNN v2: Combinando Espaço e Tempo

A arquitetura CRNN (Convolutional Recurrent Neural Network) é um modelo híbrido que integra o poder da CNN para extração de características espaciais com a capacidade da RNN para modelar dependências temporais.



Bloco CNN: 3 camadas convolucionais (32, 64, 64 filtros) processam o Log-Mel Spectrogram. Cada camada aplica convolução 2D, normalização de batch, ativação ELU e max pooling simétrico (3×3, 4×4, 4×4), extraindo características hierárquicas do espectrograma.

Reshape: A saída da CNN é reorganizada através de uma camada Lambda que transpõe os dados, preservando a dimensão temporal como sequência principal. O resultado é uma sequência (Batch × Tempo × Features) onde cada passo temporal contém as características extraídas pela CNN.

Bloco RNN: 2 camadas Bidirectional LSTM (64 unidades cada) processam a sequência temporal. A primeira camada retorna sequências completas, permitindo que a segunda processe a evolução temporal em múltiplos passos. A segunda camada agrega a informação temporal no estado final. A bidirecionalidade permite utilizar contexto passado e futuro simultaneamente, adequado para gravações offline.


Classificação: Uma camada densa final com softmax produz a predição das 10 classes, precedida por dropout e normalização de batch para regularização.

Alteração Crítica:

A grande inovação na nossa CRNN v2, foi a remoção da camada Dense entre o bloco CNN e o bloco RNN. Esta decisão permite que a LSTM receba a sequência de feature maps de forma intacta, preservando a sua integridade temporal e facilitando uma análise mais rica das dependências sequenciais.

Desempenho Global (Média 10-Folds)

Os resultados experimentais demonstram a eficácia das otimizações implementadas, com a CNN v2 a alcançar surpreendentemente o melhor desempenho global.



- **CRNN v2:** Os resultados finais revelaram uma descoberta interessante. A CRNN v2 atingiu 68.5% de acurácia, ligeiramente abaixo da CNN v2 que obteve 68.7%. Este resultado contraria a nossa hipótese inicial, mas a análise detalhada por classe mostra que a CRNN v2 é significativamente melhor para sons com padrões temporais claros, como Car Horn. Isto demonstra que a escolha do modelo deve considerar não apenas a acurácia global, mas também as características específicas das classes.
- **Ganho Consistente:** A simplificação da rede nas versões v2 resultou em melhor desempenho, mostrando que menos complexidade pode significar maior generalização.
- **Otimização sobre Complexidade:** As versões otimizadas superaram consistentemente as versões mais complexas, sublinhando a importância da regularização e do pré-processamento de dados.

Onde o Modelo Falha e Brilha? Análise por Classe

A análise detalhada por classe revela as forças e fraquezas do modelo, destacando o papel crucial da componente temporal em certos tipos de sons.

Classe de Som	RNN	CRNN v1	CNN v2	CRNN v2
Car Horn	57.5%	74.6%	77.0%	81.8%
Gun Shot	74.0%	84.4%	84.6%	83.6%
Air Conditioner	42.7%	41.9%	47.3%	50.6%

Car Horn: Ganho de +20%

A componente RNN foi decisiva para sons contínuos e modulados, como a buzina, que possuem uma clara evolução temporal.

Gun Shot: Alta Precisão

Sons distintivos e de curta duração, como disparos, são mais fáceis de identificar, apresentando alta acurácia em todos os modelos.

Air Conditioner: Baixa Precisão

Sons estacionários, como o ar condicionado, são frequentemente confundidos com ruído de fundo, representando um desafio persistente.


❏ A análise por classe mostra que a CRNNv2 é superior para sons temporais complexos, validando a abordagem híbrida para casos específicos.

Teste Rápido de Robustez e Segurança: O Ataque DeepFool em CRNN v1

Para avaliar a robustez do modelo em cenários reais, submetemo-lo a um ataque adversário DeepFool. Os resultados revelaram uma vulnerabilidade significativa. Este teste foi feito em 100 instâncias de cães a ladrar.


Espectrograma Original

Acurácia: 79%



Espectrograma Sob Ataque

Acurácia: 14%



Insight: O modelo aprendeu características discriminativas, mas não robustas a ruído malicioso. Isto tem implicações críticas para sistemas de segurança reais, onde a fiabilidade em face de ataques adversários é primordial.

Queda de Performance: Uma drástica redução de 79% para 14% na acurácia (-65%) com uma perturbação média (L2) de 5.30. Isto significa que pequenas perturbações, **impercetíveis ao ouvido humano**, podem enganar o modelo. Futuras pesquisas devem focar-se em defesas contra tais vulnerabilidades.

Conclusões e Trabalho Futuro

Este trabalho demonstrou que, com uma metodologia rigorosa e escolhas estratégicas de pré-processamento e arquitetura, é possível alcançar resultados robustos na classificação de sons urbanos.

1 Metodologia Rigorosa

A validação correta com 10-Folds é mais importante do que a complexidade da arquitetura, garantindo a generalização real do modelo.

2 Representação de Dados

Log-Mel Spectrograms provaram ser superiores a MFCCs para CNNs, permitindo uma representação visual mais rica e eficaz do som.

3 Arquitetura Otimizada

A CRNN "magra" (v2) não foi melhor que CNNv2 (68.5% vs 68.7%), evidenciando a talvez não interoperabilidade entre modelos.

4 Regularização e Overfitting

Menos parâmetros e uma arquitetura simplificada resultam em menos overfitting, crucial para datasets de menor dimensão como o UrbanSound8K.

Trabalho Futuro

Para ultrapassar a barreira dos 80% de acurácia, as próximas etapas incluem:

- **Data Augmentation Avançado:** Implementação de técnicas como SpecAugment para aumentar a diversidade dos dados de treino.
- **Transfer Learning:** Utilizar modelos pré-treinados em grandes datasets (AudioSet/YAMNet) para alavancar conhecimento existente.
- **Defesas Contra Ataques Adversários:** Desenvolver mecanismos para tornar os modelos mais robustos contra manipulações maliciosas.

O resultado de 68.7% representa uma base sólida e honesta para futuras investigações neste campo.